

UNIVERSIDAD PERUANA UNIÓN

FACULTAD DE INGENIERÍA Y ARQUITECTURA

E.P. DE INGENIERÍA DE SISTEMAS



CURSO:

Estadística para la Investigación

DOCENTE:

MILTON EDWARD HUMPIRI FLORES

CICLO: 5 **GRUPO:** 2

ALUMNOS:

ERICK MIJAEL DELGADO LIMA

MARY MARGOTH MAMANI QUISPE

JULIO RODRIGO ZEGARRA MUÑOZ

Año de la Esperanza y el Fortalecimiento de la
Democracia

2026

Indice

Introduccion

En la investigacion cuantitativa es frecuente comparar grupos para determinar si una intervencion, condicion o contexto se asocia con diferencias en una variable de interes. El analisis de varianza parametrico (ANOVA) se utiliza cuando la variable dependiente es cuantitativa, los grupos son independientes o repetidos segun el diseno, y se cumplen supuestos como normalidad, homogeneidad de varianzas e independencia. Sin embargo, en medicina, educacion e investigacion social los datos reales no siempre responden a esas condiciones: pueden presentar asimetria, valores extremos, escalas ordinales, tamanos muestrales pequenos o distribuciones con colas pesadas.

Frente a esas situaciones, las pruebas no parametricas ofrecen una alternativa metodologica robusta. En lugar de comparar directamente medias aritmeticas, muchas de estas pruebas transforman las observaciones en rangos. Esa transformacion reduce la influencia de valores extremos y permite trabajar con informacion ordinal o con datos continuos que no cumplen adecuadamente la normalidad. Kruskal-Wallis y Friedman pertenecen a esta familia de procedimientos basados en rangos y se consideran alternativas no parametricas a dos variantes del ANOVA.

La prueba de Kruskal-Wallis se aplica cuando existen tres o mas grupos independientes. Por ejemplo, permite comparar niveles de dolor entre tres tratamientos, puntajes de aprendizaje entre tres estrategias pedagogicas o indicadores de satisfaccion entre grupos sociales distintos. Su hipotesis general sostiene que las distribuciones de los grupos son equivalentes; cuando las formas de distribucion son comparables, suele interpretarse como una evaluacion de diferencias de localizacion, frecuentemente asociadas a medianas.

La prueba de Friedman, en cambio, se usa cuando las mediciones son repetidas o emparejadas. El mismo sujeto, aula, institucion o unidad de analisis es evaluado bajo varias condiciones. El procedimiento ordena las observaciones dentro de cada bloque o sujeto y analiza si algunas condiciones reciben sistematicamente rangos mas altos o mas bajos. Por eso resulta util para ensayos cruzados, comparaciones de metodos aplicados a los mismos participantes o estudios antes-durante-despues.

Este trabajo desarrolla el fundamento teorico de ambas pruebas, sus supuestos, la interpretacion de rangos, la logica de las pruebas post hoc no parametricas y las ventajas que ofrecen ante datos no normales. Ademias, se presentan aplicaciones practicas en medicina, educacion e investigacion social, junto con ejemplos resueltos y un anexo de datos que permite reproducir los calculos principales.

Objetivos

Objetivo general

Desarrollar una revision teorica y aplicada sobre las pruebas no parametricas de Kruskal-Wallis y Friedman como alternativas al ANOVA para comparar grupos independientes y mediciones repetidas cuando los datos no cumplen supuestos parametricos.

Objetivos especificos

1. Explicar el fundamento de las pruebas basadas en rangos y su relacion con el ANOVA.
2. Diferenciar el uso de Kruskal-Wallis en grupos independientes y Friedman en medidas repetidas.
3. Interpretar estadisticos, valores p, rangos promedio y comparaciones post hoc no parametricas.
4. Aplicar ambas pruebas en ejemplos vinculados con medicina, educacion e investigacion social.

Marco teorico desarrollado

1. Alternativa no paramétrica al ANOVA

El análisis de varianza (ANOVA paramétrico) es una técnica estadística utilizada para comparar las medias de tres o más grupos, descomponiendo la variabilidad total en intra e inter-grupal. Sin embargo, su validez depende de supuestos estrictos como la normalidad, homogeneidad de varianzas e independencia. En contextos reales (ciencias sociales, medicina, educación), estos supuestos a menudo no se cumplen debido a la presencia de valores atípicos, escalas ordinales, tamaños muestrales pequeños o asimetría, lo que limita su utilidad.

Ante estas limitaciones, las pruebas no paramétricas, como Kruskal-Wallis y Friedman, surgen como alternativas robustas. Estas pruebas no requieren una distribución normal estricta y basan su análisis en rangos —el orden relativo de las observaciones— en lugar de en medias aritméticas, mitigando así el impacto de valores extremos.

Kruskal-Wallis se aplica en diseños de grupos independientes (ej. comparar el rendimiento de tres métodos de enseñanza), mientras que Friedman se utiliza para diseños de medidas repetidas o datos relacionados (ej. evaluar un mismo grupo de pacientes en distintos momentos). Ambas pruebas no deben considerarse inferiores al ANOVA, sino metodologías adecuadas para variables ordinales, escalas de Likert y datos no normales.

Su lógica central evalúa si las diferencias en los rangos promedio entre grupos o condiciones son estadísticamente significativas para rechazar la hipótesis nula, la cual plantea la igualdad de distribuciones. Aunque ofrecen ventajas claras en términos de resistencia a outliers y flexibilidad con datos ordinales, poseen la limitación de perder parte de la información numérica exacta. Por ello, la elección entre una prueba paramétrica y una no paramétrica debe basarse en el tipo de variable, el diseño del estudio y el cumplimiento de los supuestos estadísticos.

2. Concepto de pruebas basadas en rangos

Las pruebas basadas en rangos son esenciales en estadística no paramétrica, ya que analizan la posición de los datos en un conjunto ordenado en lugar de sus valores originales. Un rango representa el orden relativo de una observación: al ordenar los datos de menor a mayor, cada uno recibe un valor de posición. En caso de empates, se asigna el promedio de los rangos correspondientes.

Este enfoque permite trabajar con variables ordinales o datos que no cumplen supuestos de normalidad y reduce significativamente la influencia de valores extremos, que en análisis paramétricos podrían sesgar las medias. Al transformar datos a rangos, la pregunta estadística cambia: se deja de comparar medias aritméticas para evaluar si las distribuciones o tendencias relativas de los grupos difieren.

Por ello, la interpretación debe ser cautelosa: al no comparar medias, no es correcto afirmar que un promedio es mayor que otro. Es más preciso señalar que un grupo tiende a presentar valores más altos o que sus observaciones ocupan rangos superiores.

En Kruskal-Wallis, los rangos se calculan globalmente para grupos independientes, mientras que en Friedman se asignan dentro de cada bloque para mediciones repetidas, controlando así la variabilidad individual. En resumen, el uso de rangos conserva la información ordinal, permite manejar distribuciones

asimétricas y proporciona una base robusta para la inferencia cuando las condiciones para pruebas paramétricas no se cumplen.

3. Kruskal-Wallis: grupos independientes

La prueba de Kruskal-Wallis, propuesta en 1952, es la alternativa no paramétrica al ANOVA de un factor para comparar tres o más grupos independientes cuando no se cumplen los supuestos de normalidad o la variable es ordinal. Aunque puede aplicarse a dos grupos (aproximándose a Mann-Whitney), su uso principal es el análisis comparativo de múltiples muestras independientes.

Fundamento y Procedimiento

La prueba no compara medias, sino rangos. El procedimiento consiste en combinar todas las observaciones, ordenarlas de menor a mayor y asignarles rangos globales. En caso de empates, se asigna el rango promedio. Posteriormente, se calcula la suma o el promedio de los rangos para cada grupo. Bajo la hipótesis nula, se espera que los rangos promedio sean similares entre grupos; si un grupo presenta rangos sistemáticamente superiores o inferiores, el estadístico H aumenta, indicando posibles diferencias en las distribuciones.

Hipótesis y Estadístico H

- **Hipótesis Nula (H_0):** Las poblaciones de los grupos tienen distribuciones similares (sin diferencias significativas en la tendencia central o dispersión).
- **Hipótesis Alternativa (H_1):** Al menos un grupo difiere de los demás.
- **Estadístico H :** Se compara con una distribución chi-cuadrado con $k-1$ grados de libertad (donde k es el número de grupos). Un valor $p < 0.05$ sugiere rechazar H_0 .

Interpretación y Consideraciones

La prueba informa sobre la existencia de una diferencia global, no sobre qué grupos específicos difieren. Por ello, si el resultado es significativo, deben aplicarse pruebas post hoc (como Dunn o Conover) con ajustes por comparaciones múltiples (ej. Holm o Bonferroni) para evitar errores de tipo I. Es recomendable reportar los rangos promedio junto con estadísticos descriptivos (medianas, gráficos de caja). Un rango promedio elevado sugiere que ese grupo tiende a valores superiores.

Ventajas y Limitaciones

- **Ventajas:** Robusta ante valores atípicos y adecuada para datos no normales u ordinales (ej. escalas Likert, niveles de dolor).
- **Limitaciones:** Requiere independencia de observaciones (no usar para medidas repetidas); pierde algo de información numérica frente al ANOVA; y, con muestras muy pequeñas (se recomienda ≥ 5 por grupo), la aproximación chi-cuadrado puede ser menos precisa.

En resumen, Kruskal-Wallis es esencial en investigación aplicada (medicina, educación, psicología) cuando el diseño es independiente y la naturaleza de los datos impide el uso de pruebas paramétricas tradicionales.

4. Supuestos e hipótesis de Kruskal-Wallis

Aunque la prueba de Kruskal-Wallis se clasifica como no paramétrica, esto no implica que carezca de rigor metodológico. La denominación "no paramétrica" o "libre de distribución" indica que la prueba no requiere que los datos sigan una distribución normal (como la campana de Gauss) ni que las varianzas sean homogéneas. Sin embargo, su validez y la interpretación correcta de sus resultados dependen estrictamente del cumplimiento de supuestos metodológicos fundamentales.

4.1. Pilares metodológicos

Para garantizar la fiabilidad del análisis, deben verificarse las siguientes condiciones antes de la ejecución:

1. **Independencia de las observaciones:** Este es el supuesto más crítico. Cada unidad de análisis debe pertenecer exclusivamente a un grupo de comparación. Las observaciones no deben estar relacionadas entre sí; si el diseño implica que los mismos sujetos son evaluados en diferentes condiciones (medidas repetidas o muestras pareadas), la prueba de Kruskal-Wallis es inapropiada, ya que violaría la independencia, aumentando el riesgo de errores tipo I. En tales casos, debe emplearse la prueba de Friedman.
2. **Naturaleza de la variable:** La variable dependiente debe ser, como mínimo, de escala ordinal. Es decir, debe ser posible establecer un orden lógico (mayor que, menor que, igual) entre las categorías o valores. Por lo tanto, no es adecuada para variables nominales sin jerarquía natural (ej. "tipo de carrera" o "color favorito"). Si la variable es continua pero no cumple la normalidad, Kruskal-Wallis es ideal, ya que su lógica de rangos preserva la información del orden sin depender de la distancia exacta entre puntos.
3. **Tamaño muestral:** Si bien la prueba es robusta, una regla práctica recomendada en la literatura estadística (como en la aproximación asintótica a la distribución chi-cuadrado) es contar con un mínimo de cinco observaciones por grupo. En muestras muy pequeñas, la aproximación chi-cuadrado pierde precisión, requiriendo métodos de permutación o exactos para mantener la validez.

4.2. Hipótesis estadística: La prueba como "Omnibus"

La hipótesis nula (H_0) de Kruskal-Wallis postula que las poblaciones de los k grupos tienen distribuciones idénticas. En un nivel técnico, esto significa que la probabilidad de que una observación extraída de un grupo sea mayor que la de otro es igual a 0.5. Si las distribuciones de los grupos tienen formas comparables (misma dispersión y asimetría), esta hipótesis puede interpretarse como una igualdad en la localización central (igualdad de medianas).

Por otro lado, la hipótesis alternativa (H_1) sostiene que al menos una de las distribuciones de los grupos difiere de las demás. Es fundamental comprender que Kruskal-Wallis es una **prueba "omnibus"**; esto significa que un resultado significativo ($p < \alpha$) nos indica que existe evidencia global de diferencia entre los grupos, pero no identifica qué grupos específicos son los que difieren entre sí.

4.3. Interpretación de la significancia y distribuciones

Al obtener un resultado significativo, es un error frecuente asumir automáticamente que "las medianas son diferentes". Si las distribuciones comparadas tienen formas muy dispares —por ejemplo, una

muestra muy dispersa comparada con una muy concentrada—, el resultado significativo podría reflejar una diferencia en la variabilidad o en la tendencia general de los rangos (dominancia estocástica), y no necesariamente un cambio en la mediana.

Por esta razón, la interpretación debe seguir este protocolo:

1. **Verificación visual:** Antes de concluir, se recomienda realizar gráficos descriptivos (diagramas de caja, gráficos de violín) para comparar visualmente las formas de distribución.
2. **Análisis Post Hoc:** Ante un resultado significativo, es obligatorio aplicar pruebas post hoc (como la prueba de Dunn, Nemenyi o Conover) con ajustes por comparaciones múltiples (ej. Bonferroni o Holm) para controlar la tasa de error experimental y aislar los pares de grupos que realmente difieren.
3. **Contextualización:** Se deben reportar los rangos promedio, el tamaño del efecto y, si la forma de las distribuciones es similar, la mediana y el rango intercuartílico como medidas de tendencia central y dispersión, respectivamente.

En resumen, la aplicación de Kruskal-Wallis trasciende el simple cálculo del estadístico H. Requiere un análisis integral que valide el diseño independiente, la naturaleza ordenada de los datos y una interpretación prudente que reconozca tanto las diferencias globales como las limitaciones inherentes a la comparación de rangos frente a la comparación de parámetros tradicionales.

5. Estadístico H e interpretación

El estadístico H es el valor principal que se obtiene al aplicar la prueba de Kruskal-Wallis. Este estadístico permite evaluar si existen diferencias significativas entre los grupos comparados a partir de sus rangos. A diferencia del ANOVA, que utiliza medias y varianzas, Kruskal-Wallis trabaja con los rangos asignados a las observaciones. Por ello, el valor H resume qué tan separados se encuentran los rangos promedio de los grupos.

Conceptualmente, el estadístico H aumenta cuando los rangos promedio de los grupos se diferencian de manera considerable. Si todos los grupos presentan rangos promedio similares, significa que sus valores se distribuyen de forma parecida dentro del conjunto total de datos. En ese caso, el valor H será bajo y el valor p tenderá a ser alto, por lo que no habría evidencia suficiente para rechazar la hipótesis nula. En cambio, si uno o más grupos concentran rangos claramente más altos o más bajos, el valor H se incrementa y puede indicar una diferencia estadísticamente significativa.

El cálculo del estadístico H toma en cuenta el número total de observaciones, el tamaño de cada grupo y la suma de rangos de cada grupo. Aunque la fórmula puede variar ligeramente cuando se aplican correcciones por empates, la idea central se mantiene: comparar la distribución de los rangos entre los grupos. Por eso, H funciona como una medida de discrepancia global entre las posiciones relativas de los grupos. Cuanto mayor sea esa discrepancia, mayor será la evidencia contra la igualdad entre ellos.

La interpretación del estadístico H debe realizarse en tres niveles. El primer nivel es la significancia global. Este nivel responde a la pregunta principal: ¿existe evidencia estadística de que al menos un grupo difiere de los demás? Para responderla, se observa el valor p asociado al estadístico H. Si el valor p

es menor que el nivel de significancia establecido, generalmente 0.05, se rechaza la hipótesis nula. Esto permite afirmar que existen diferencias significativas entre los grupos. Sin embargo, este resultado no indica todavía cuáles grupos son diferentes entre sí.

El segundo nivel de interpretación corresponde a la dirección de los rangos. Para ello, se revisan los rangos promedio de cada grupo. Un grupo con rango promedio más alto tiende a presentar valores mayores en la variable analizada. Por el contrario, un grupo con rango promedio más bajo tiende a presentar valores menores. Esta lectura es importante porque permite comprender el sentido de la diferencia. No obstante, debe evitarse afirmar directamente que un grupo tiene “mayor media”, ya que la prueba no compara medias aritméticas, sino posiciones relativas.

El tercer nivel corresponde a la magnitud práctica de la diferencia. Una prueba puede resultar estadísticamente significativa, pero eso no siempre significa que la diferencia sea importante en términos reales. Por ello, además del valor H y el valor p , se deben revisar las medianas, los rangos intercuartílicos, los gráficos y, cuando sea posible, los tamaños de efecto. Estos elementos permiten evaluar si la diferencia encontrada tiene relevancia práctica en el contexto de la investigación. Por ejemplo, en educación, una diferencia estadística entre métodos de enseñanza debe analizarse también considerando si el cambio en el rendimiento es realmente útil o significativo para el aprendizaje.

También es recomendable utilizar gráficos para apoyar la interpretación. Los diagramas de caja permiten observar la mediana, la dispersión y la presencia de valores atípicos en cada grupo. Los gráficos de violín o histogramas permiten visualizar la forma de las distribuciones. Estos recursos ayudan a comprender si las diferencias detectadas por la prueba se deben a cambios en la localización central, a diferencias en la dispersión o a una distribución más asimétrica en alguno de los grupos.

Un aspecto importante en el cálculo del estadístico H es la presencia de empates. Los empates ocurren cuando dos o más observaciones tienen el mismo valor. Esto es común en variables ordinales, especialmente en escalas tipo Likert, donde varias personas pueden seleccionar la misma respuesta, por ejemplo, “de acuerdo” o “muy de acuerdo”. Cuando hay muchos empates, el estadístico H puede verse afectado, por lo que se aplica una corrección para evitar que la evidencia estadística sea sobrestimada. La mayoría de programas estadísticos, como SPSS, R, Python o Jamovi, realizan esta corrección automáticamente.

En la redacción de resultados, se recomienda presentar el estadístico H junto con los grados de libertad, el valor p y una breve interpretación de los rangos. Por ejemplo, se podría escribir: “La prueba de Kruskal-Wallis mostró diferencias significativas entre los tres métodos de enseñanza, $H(2) = 8.45$, $p = 0.015$. El método C presentó el rango promedio más alto, lo que sugiere una tendencia a obtener mayores puntajes de rendimiento”. Esta forma de reporte permite comunicar tanto la significancia estadística como la dirección de los resultados.

En conclusión, el estadístico H es el indicador central de la prueba de Kruskal-Wallis y permite evaluar si los grupos independientes presentan diferencias en sus rangos. Su interpretación no debe limitarse al valor p , sino que debe incluir la significancia global, la dirección de los rangos y la magnitud práctica de las diferencias. Además, es necesario considerar los empates, revisar las distribuciones y complementar

el análisis con medidas descriptivas y gráficos. De esta manera, la interpretación de Kruskal-Wallis será más completa, clara y adecuada al contexto de investigación.

6. Friedman: medidas repetidas

La prueba de Friedman constituye el procedimiento no paramétrico de referencia para contrastar tres o más condiciones relacionadas. Su aplicación es fundamental cuando las mismas unidades de análisis (sujetos, instituciones o bloques) son evaluadas bajo múltiples momentos, tratamientos o situaciones experimentales. Metodológicamente, se erige como la alternativa robusta al ANOVA de medidas repetidas, resultando indispensable cuando no se satisfacen supuestos de normalidad, se trabaja con escalas ordinales o se requiere mitigar el impacto de la heterogeneidad individual entre los participantes.

Bajo este diseño, la unidad de análisis presenta una naturaleza diversa: puede tratarse de un paciente, estudiante, centro educativo, organización, sector geográfico o incluso un algoritmo contrastado en diversos repositorios de datos. El requisito sine qua non es que cada unidad aporte mediciones en todas las condiciones comparadas. Ejemplos típicos incluyen la evaluación de un grupo de alumnos tras experimentar tres metodologías pedagógicas, el seguimiento del nivel de dolor en pacientes en un diseño antes-durante-después, o el benchmarking de algoritmos sobre los mismos conjuntos de datos; en todos estos escenarios, las observaciones guardan una relación intrínseca al emanar de las mismas unidades.

La distinción operativa crucial entre Friedman y Kruskal-Wallis reside en el proceso de asignación de rangos. Mientras que Kruskal-Wallis agrupa todas las observaciones para establecer rangos globales, Friedman los asigna exclusivamente dentro de cada bloque o sujeto. Esta lógica implica que las comparaciones se ejecutan intrasujeto (dentro de cada fila), transformando a cada bloque en su propio marco de referencia, lo cual evita que las variaciones entre diferentes unidades contaminen la comparación de las condiciones.

Ilustrativamente, si un estudiante es evaluado bajo tres estrategias de enseñanza, sus puntajes se ordenan únicamente en relación con su propio desempeño: la calificación más baja recibe el rango 1 y la más alta el rango 3. Este procedimiento se replica para cada participante, procediendo finalmente a la suma de rangos por cada método evaluado. Si una condición acumula rangos superiores de forma sistemática a través de la muestra, se infiere una tendencia a generar resultados más favorables en comparación con las alternativas contrastadas.

Este mecanismo permite una neutralización efectiva de la variabilidad individual. En la práctica investigativa, los sujetos raramente presentan un punto de partida idéntico: existen diferencias de habilidad innata, severidad basal de síntomas o recursos institucionales previos. Si el análisis se basara en valores absolutos, tales disparidades podrían sesgar las conclusiones. Friedman solventa este inconveniente al enfocarse en el orden de prelación de las condiciones dentro de cada unidad, priorizando la dirección del cambio sobre la magnitud bruta del puntaje.

Consecuentemente, esta prueba destaca por su eficacia cuando existe alta varianza intersujeto, permitiendo que cada individuo actúe como su propio control interno. Un estudiante con alto rendimiento académico constante no distorsiona el contraste global, pues el interés analítico recae en

determinar cuál método propició su mejor resultado relativo. De este modo, el procedimiento estadístico se concentra en aislar el efecto de las condiciones experimentales, blindando los resultados frente a las diferencias de base de los participantes.

La hipótesis nula (H_0) en Friedman postula la equivalencia en las distribuciones de las condiciones evaluadas, sugiriendo que los tratamientos o momentos comparados ejercen efectos indistinguibles sobre las unidades de análisis. Bajo este supuesto, se esperaría una paridad en los rangos promedio. Por el contrario, la hipótesis alternativa (H_1) sostiene que al menos una condición difiere significativamente, manifestando una tendencia sistemática a ocupar posiciones superiores o inferiores en la jerarquía de rangos.

El cálculo del estadístico de Friedman se deriva de las sumas de rangos por condición. Una convergencia en estas sumas arrojará un estadístico reducido y un valor p elevado, impidiendo el rechazo de H_0 . No obstante, si una condición concentra rangos atípicos, el estadístico se incrementa indicando discrepancias significativas. Con tamaños muestrales adecuados, dicho valor se aproxima a una distribución chi-cuadrado con $k-1$ grados de libertad, donde k representa el número total de condiciones en estudio.

Es imperativo notar que un resultado significativo revela una diferencia de carácter global u "omnibus", sin precisar qué pares de condiciones son los responsables del efecto. Si un estudio pedagógico sobre tres métodos arroja significancia, solo se confirma que no son equivalentes. Para desentrañar la estructura de las diferencias, se requiere la aplicación de pruebas post hoc para datos relacionados, tales como comparaciones pareadas con ajustes de Bonferroni, Holm o el procedimiento de Nemenyi, garantizando así el control del error tipo I.

La interpretación debe fundamentarse en los rangos promedio de cada condición: valores más elevados denotan una dominancia dentro de los bloques evaluados. Sin embargo, en consonancia con la naturaleza de las pruebas basadas en rangos, debe evitarse la atribución de diferencias en las medias aritméticas. La conclusión correcta debe enunciarse en términos de tendencias de localización o posiciones relativas, reconociendo que el análisis opera sobre la jerarquía y no sobre los parámetros originales de la escala.

En el ámbito educativo, Friedman resulta óptima para monitorizar el progreso académico bajo distintas intervenciones pedagógicas (tradicional vs. colaborativa vs. virtual) aplicadas a los mismos alumnos. Asimismo, permite evaluar la evolución de la satisfacción estudiantil en diversos hitos temporales del semestre. En estos contextos, la dependencia de los datos es la característica definitoria, dado que el mismo colectivo es evaluado de forma recurrente, justificando el uso de este procedimiento no paramétrico.

Dentro de la investigación médica, su utilidad es patente al analizar la trayectoria clínica de pacientes bajo regímenes terapéuticos específicos o en estudios longitudinales de dolor (basal, seguimiento corto y largo plazo). Al funcionar cada paciente como su propio bloque, Friedman ofrece mayor precisión que Kruskal-Wallis para detectar cambios intraindividuales, manejando con solvencia datos que suelen presentar asimetría o escalas de calificación subjetiva.

En las ciencias sociales, la prueba facilita la comparación de percepciones o actitudes ciudadanas frente a diversos escenarios, instituciones o políticas públicas evaluadas por los mismos participantes. Esta estrategia analítica permite discernir si existen jerarquías sistemáticas en la opinión pública, minimizando

sesgos de respuesta individuales y permitiendo una lectura más fiel de las preferencias relativas de los sujetos consultados.

Una ventaja sustancial de Friedman es su independencia respecto al supuesto de normalidad, lo que la valida para escalas Likert, variables con valores extremos o muestras reducidas. Al operar con rangos intrabloque, incrementa la robustez del análisis frente a outliers y heterogeneidad individual, consolidándose como una herramienta versátil en la investigación aplicada donde las condiciones ideales para las pruebas paramétricas rara vez se presentan en la práctica.

No obstante, la prueba conlleva limitaciones críticas: exige que todos los bloques cuenten con mediciones completas en todas las condiciones (sensibilidad a datos faltantes), requiere que la variable sea estrictamente ordenable y su naturaleza omnibus obliga a complementar el hallazgo con análisis post hoc para una interpretación detallada. Sin estos requisitos y procedimientos adicionales, la validez del contraste y su utilidad práctica para la toma de decisiones podrían verse comprometidas.

En conclusión, la prueba de Friedman se consolida como la solución no paramétrica idónea para comparar tres o más mediciones repetidas o condiciones relacionadas. Su lógica de rangos intrabloque permite un control riguroso de la varianza individual, resultando esencial ante datos no normales o variables ordinales. Su correcta implementación exige una visión integral que abarque desde la validación del diseño dependiente hasta el uso de ajustes post hoc, garantizando conclusiones precisas sobre las diferencias entre tratamientos, momentos o metodologías en estudio.

7. Supuestos e hipótesis de Friedman

La validez de la prueba de Friedman, aun dentro del marco no paramétrico, depende del cumplimiento de directrices metodológicas específicas. Aunque prescinde del supuesto de normalidad, su ejecución exige un diseño de medidas repetidas o bloques relacionados, donde las unidades de análisis sean evaluadas bajo múltiples condiciones. Antes de proceder con el cálculo del estadístico, es imperativo constatar que la estructura de los datos permita una comparación intrasujeto coherente y que cada bloque suministre información para todos los escenarios contrastados.

El pilar fundamental de Friedman es la configuración de bloques comparables. Un bloque constituye la unidad mínima de evaluación —sea un paciente, estudiante, institución o empresa— que atraviesa diversas situaciones experimentales. En el ámbito educativo, si un mismo colectivo de alumnos experimenta tres estrategias pedagógicas, cada estudiante actúa como su propio bloque. La esencia del procedimiento radica en analizar las variaciones internas de estas unidades, neutralizando así la variabilidad que existe entre sujetos independientes.

Como segundo requisito, se establece que cada unidad de análisis debe aportar observaciones completas para la totalidad de las condiciones en estudio. Esta simetría estructural es necesaria para que cada participante disponga de registros en cada hito temporal o tratamiento. En un diseño longitudinal de antes-durante-después, la ausencia de un valor en cualquier etapa rompe la secuencia de rangos intrabloque, comprometiendo la base comparativa sobre la cual se calculan las sumas de rangos por condición.

La gestión de datos faltantes representa un desafío crítico para la robustez del análisis. Ante omisiones esporádicas, los paquetes estadísticos suelen optar por la exclusión de bloques incompletos, centrando el cálculo en los casos con información íntegra. No obstante, una pérdida sustancial de datos puede mermar drásticamente la potencia estadística y sesgar las conclusiones. En tales escenarios, se aconseja transitar hacia modelos de medidas repetidas más versátiles o técnicas de imputación que preserven la integridad del diseño original.

Un tercer supuesto ineludible es la naturaleza ordenable de la variable dependiente. Al fundamentarse en rangos, Friedman requiere escalas de medición que admitan una jerarquía lógica (mayor, menor o igual). Variables vinculadas al rendimiento académico, la percepción del dolor o la satisfacción ciudadana son candidatos ideales. Por el contrario, atributos nominales sin un orden intrínseco, como la filiación religiosa o el grupo sanguíneo, resultan incompatibles con la lógica posicional de este procedimiento.

Asimismo, la equivalencia de los criterios de evaluación entre condiciones es vital para la coherencia del modelo. Si se contrastan diversos métodos de instrucción, todos deben ser fiscalizados mediante instrumentos o rúbricas con propiedades métricas comparables. Una disparidad en los contextos de medición o en la naturaleza de las escalas podría distorsionar la asignación de rangos, generando una interpretación confusa de las tendencias detectadas por la prueba.

La hipótesis nula (H_0) postula que las condiciones evaluadas presentan distribuciones equivalentes dentro de los bloques, sugiriendo que el efecto de los tratamientos o momentos es indistinguible. Bajo esta premisa de paridad, se esperaría que los rangos promedio de las condiciones no muestren desviaciones sistemáticas. Por ejemplo, si tres intervenciones clínicas son igualmente efectivas, ninguna debería concentrar de forma recurrente los rangos más altos o bajos a través de la muestra de pacientes.

En contraste, la hipótesis alternativa (H_1) sostiene que al menos una condición manifiesta una tendencia diferencial, ocupando posiciones jerárquicas superiores o inferiores de manera consistente. Si una herramienta digital propicia sistemáticamente mejores desempeños en la mayoría de los alumnos, la prueba detectará esta dominancia estocástica. Sin embargo, Friedman opera como una prueba "omnibus": confirma la existencia de una discrepancia global pero no identifica específicamente qué pares de condiciones son los causantes del efecto.

Consecuentemente, ante un hallazgo significativo, es mandatorio ejecutar análisis post hoc para datos relacionados. Estos contrastes pormenorizados permiten discernir si la divergencia radica entre los métodos A y B, o si se manifiesta en otros cruces específicos. Para blindar la investigación contra errores de tipo I, estas comparaciones deben incorporar ajustes por multiplicidad, tales como los procedimientos de Bonferroni, Holm o Nemenyi, garantizando la fiabilidad de las diferencias aisladas.

La fundamentación matemática de Friedman suele descansar en la distribución chi-cuadrado, especialmente cuando el volumen de bloques es representativo. Los grados de libertad se definen mediante la expresión $k-1$, siendo k el número de condiciones evaluadas. Este marco probabilístico facilita la obtención del valor p , el cual actúa como el criterio decisorio para el rechazo de la hipótesis nula en favor de la evidencia experimental acumulada en los rangos.

No obstante, la precisión de la aproximación chi-cuadrado flaquea ante tamaños muestrales reducidos o un número limitado de condiciones. En tales circunstancias, la inferencia debe manejarse con prudencia, recurriendo preferiblemente a métodos exactos o simulaciones de permutación para salvaguardar la

validez. Esta cautela es indispensable en dominios como la medicina o la intervencion social, donde las decisiones basadas en el analisis estadistico tienen repercusiones directas en la practica profesional.

La gestion de empates tambien demanda atencion analitica. Cuando dos o mas condiciones reciben puntajes identicos dentro de un bloque —fenomeno frecuente en escalas tipo Likert—, se procede a asignar el promedio de los rangos en disputa. Si bien el software estadistico contemporaneo automatiza esta correccion, el investigador debe reportar su incidencia, dado que una alta densidad de empates puede atenuar la sensibilidad de la prueba y alterar la interpretacion de la potencia analitica.

En terminos de comunicacion de resultados, Friedman permite discernir que condiciones ejercen una dominancia relativa en la jerarquia de los bloques. Es metodologicamente incorrecto enunciar conclusiones en terminos de "medias aritmeticas superiores", pues el analisis no opera sobre parametros originales. La redaccion tecnica debe enfatizar que una condicion "presento rangos promedio mas elevados" o "mostro una tendencia a valores superiores", respetando la naturaleza no parametrica del contraste efectuado.

Para una interpretacion integral, se recomienda flanquear el estadistico con medidas descriptivas robustas y recursos graficos. Las medianas, los rangos intercuartiles y las representaciones visuales, como graficos de lineas intrasujeto, permiten visualizar si la tendencia detectada es transversal a la muestra o si esta influenciada por bloques atipicos. Esta vision holistica asegura que las conclusiones no solo sean estadisticamente validas, sino tambien sustantivas y aplicables al contexto de la investigacion.

En sintesis, el exito de la prueba de Friedman radica en la coherencia del diseno de bloques relacionados, la integridad de los datos y el cumplimiento del supuesto de ordinalidad. Su capacidad para detectar diferencias en condiciones repetidas debe complementarse siempre con ajustes post hoc y una lectura cautelosa de los rangos. Solo mediante un reporte transparente que incluya descriptivos y graficos se puede garantizar una toma de decisiones informada y resistente a las desviaciones de la normalidad habituales en datos reales.

8. Interpretacion de rangos

El analisis de los rangos constituye un pilar fundamental en la estadistica no parametrica, particularmente en los contrastes de Kruskal-Wallis y Friedman. Dado que estos procedimientos prescinden de los valores originales para centrarse en la posicion relativa de cada observacion dentro de una jerarquia ordenada, los rangos promedio actuan como el vinculo analitico entre el estadistico calculado y la conclusion sustantiva del estudio. Una comprension rigurosa de esta metrica es imperativa para evitar sesgos interpretativos y garantizar que las inferencias derivadas del ordenamiento posicional sean tecnicamente precisas y coherentes con la naturaleza de los datos.

En el contexto de la prueba de Kruskal-Wallis, la asignacion de rangos se ejecuta de manera global, integrando todas las observaciones de los grupos independientes en un unico conjunto ordenado. Posteriormente, se deriva el rango promedio para cada nivel del factor comparado. Un rango promedio elevado denota una dominancia estocastica del grupo, indicando que sus observaciones tienden a ocupar posiciones superiores en el espectro total de la muestra. Por el contrario, un rango promedio reducido sugiere una concentracion sistematica de la categoria en los estratos inferiores de la distribucion global.

Por ejemplo, si un investigador educativo contrasta tres estrategias de instruccion y observa que el metodo digital alcanza el rango promedio mas alto, se infiere una tendencia de este grupo hacia niveles de rendimiento superiores. No obstante, esta lectura exige cautela metodologica: es un error conceptual atribuirle una “mayor media aritmetica” al grupo, puesto que la prueba opera sobre el orden relativo y no sobre parametros de tendencia central tradicionales. Una redaccion tecnicamente correcta indicaria: *“El metodo digital manifesto el rango promedio superior, sugiriendo una propension hacia valores mas elevados en la escala de evaluacion”*.

En contraposicion, la prueba de Friedman emplea una logica de rangos intrabloque, propia de los disenos de medidas repetidas o datos relacionados. Aqui, la ordenacion se realiza exclusivamente dentro de cada unidad de analisis (sujeto o bloque), comparando al participante consigo mismo a traves de las diversas condiciones experimentales. Un rango promedio alto en este escenario revela que una condicion especifica tiende a prevalecer jerarquicamente sobre las demas dentro de los mismos individuos. Asi, en un seguimiento longitudinal de aprendizaje, un rango superior para la intervencion digital confirmaria su eficacia relativa frente a las demas alternativas evaluadas en el mismo colectivo.

Esta distincion operativa entre Kruskal-Wallis y Friedman es critica para la integridad del analisis. Mientras que en el primer caso los rangos promedio discriminan entre grupos independientes, en el segundo reflejan la jerarquizacion de condiciones dentro de bloques vinculados. Consecuentemente, el reporte de resultados debe alinearse estrictamente con el diseno: en disenos independientes se enfatizan las tendencias intergrupales, mientras que en mediciones repetidas el foco analitico reside en la evolucion o preferencia relativa dentro de las unidades de analisis.

Es imperativo no homologar los rangos promedio con el promedio de la variable original. Aunque ambas metricas suelen presentarse de forma conjunta, sus fundamentos teoricos divergen: la media aritmetica es sensible a la magnitud exacta de los valores, mientras que el rango promedio se basa en la posicion tras el ordenamiento. Esta discrepancia es especialmente visible ante la presencia de valores atipicos (outliers), empates masivos o distribuciones asimetricas, donde un grupo puede exhibir un rango promedio dominante incluso si su media no manifiesta una superioridad clara respecto a los demas niveles.

Ilustrativamente, un grupo con valores extremos podria presentar una media elevada pero un rango promedio moderado si la mayoria de sus observaciones se situan en la zona media de la distribucion. Inversamente, un grupo con datos consistentes y ligeramente superiores al resto alcanzara un rango promedio elevado, independientemente de que carezca de picos de magnitud. Esta diferencia subraya la importancia de interpretar los rangos como indicadores de tendencia relativa y no como sustitutos directos de los parametros parametricos convencionales.

La incidencia de empates —frecuente en escalas de tipo Likert u ordinales de rango limitado— tambien modula la interpretacion. En estos casos, se asigna el promedio de los rangos en conflicto a las observaciones identicas. Si bien este ajuste es estandar en el software estadistico, una alta densidad de empates puede atenuar la sensibilidad de la prueba y reducir la nitidez de las diferencias detectadas. Por ello, en investigaciones que emplean variables con categorias reducidas, la lectura de las tendencias debe ser prudente y estar respaldada por un analisis de frecuencias.

Asimismo, la asimetria en las distribuciones afecta la decodificacion de los rangos. En conjuntos de datos con colas pesadas o concentraciones en los extremos, el rango promedio refleja cambios en la

morfología general de la distribución y no solo desplazamientos en la localización central. Por esta razón, un hallazgo significativo no debe traducirse automáticamente como una “diferencia de medianas”; en ocasiones, el resultado revela una dominancia estocástica vinculada a la variabilidad o a la forma de la distribución, exigiendo una evaluación holística del comportamiento de los datos.

Para robustecer la discusión de resultados, se recomienda flanquear el análisis de rangos con medidas descriptivas no paramétricas como la mediana y el rango intercuartílico. La mediana proporciona una referencia de la tendencia central resistente a outliers, mientras que el rango intercuartílico cuantifica la dispersión de los datos nucleares. Estas métricas, junto con el tamaño muestral de cada celda, ofrecen un marco de interpretación coherente que respeta la naturaleza no paramétrica del contraste y enriquece la profundidad del informe técnico.

La visualización de datos mediante recursos gráficos es, de igual modo, una práctica de reporte esencial. El uso de diagramas de caja (boxplots) permite escrutar la mediana, la simetría y la presencia de casos atípicos en cada grupo. En el caso de medidas repetidas, los gráficos de líneas intrasujeto o gráficos de violín facilitan la comprensión de las trayectorias individuales y la forma de las distribuciones. Estas herramientas visuales permiten discernir si la tendencia reflejada en los rangos es una característica transversal del grupo o si esta condicionada por observaciones extremas.

Los rangos promedio también facilitan la traducción de los hallazgos a implicancias prácticas en diversos campos. En educación, la dominancia de una estrategia pedagógica en los rangos sugiere una mejora sustantiva en el desempeño; en medicina, una disminución en los rangos de una escala de dolor tras un tratamiento indica una eficacia clínica tangible; y en ciencias sociales, rangos más altos en encuestas de satisfacción revelan una percepción ciudadana más favorable. No obstante, la dirección de la diferencia siempre debe contextualizarse según el sentido semántico de la escala utilizada.

En este sentido, un valor elevado en el rango no siempre es sinónimo de un resultado positivo. En indicadores de riesgo, ansiedad o sintomatología clínica, un rango alto representa una condición desfavorable que el investigador debe identificar con claridad. Por el contrario, en variables de aprovechamiento, calidad de vida o satisfacción, la superioridad jerárquica es interpretada como un éxito institucional o clínico. Por tanto, la redacción de las conclusiones debe estar precedida por una revisión exhaustiva del significado operativo de los valores altos y bajos en la variable de estudio.

Finalmente, la comunicación efectiva de los resultados exige trascender el mero reporte de la significancia estadística. No es suficiente declarar que la prueba fue significativa ($p < .05$); es preciso explicar cuál es la condición que manifiesta la tendencia diferencial y qué relevancia tiene este hallazgo para el problema de investigación. Un informe integral debe armonizar el estadístico global, el valor p , los rangos promedio, las medidas de dispersión y la magnitud práctica de las diferencias para orientar la toma de decisiones informada.

En síntesis, la interpretación de rangos es el eje articulador de los contrastes de Kruskal-Wallis y Friedman. Mientras que el primero evalúa la posición de grupos independientes en la distribución global, el segundo analiza la jerarquización intrasujeto en condiciones repetidas. Al tratarse de indicadores de tendencia relativa y no de medias aritméticas, su uso exige el acompañamiento de descriptivos robustos, soporte gráfico y una lectura contextualizada. Solo mediante este enfoque integral se logra una interpretación fiel de los datos no normales, comúnmente presentes en la práctica investigativa real.

9. Pruebas post hoc no parametricas

Tras la obtencion de un hallazgo significativo en un contraste global como Kruskal-Wallis o Friedman, es imperativo ejecutar **pruebas post hoc no parametricas**. Su funcion es desentrañar la estructura de las divergencias, identificando especificamente que pares de grupos o condiciones manifiestan disparidades. Dado que los procedimientos omnibus solo confirman la existencia de una falta de equivalencia general, no permiten discernir que niveles del factor son los responsables del efecto. Ilustrativamente, en un estudio pedagogico sobre tres estrategias, la significancia global solo revela que no son indistinguibles, sin precisar si la dominancia radica entre A y B, A y C, o en el cruce entre B y C.

En el marco de Kruskal-Wallis, los analisis posteriores se orientan a la comparacion de unidades independientes. La prueba de *Dunn* destaca como una de las soluciones mas extendidas, pues mantiene la coherencia con la logica de rangos globales. Alternativamente, pueden emplearse contrastes pareados mediante *U de Mann-Whitney*, siempre que se incorporen ajustes por multiplicidad. El procedimiento de *Conover-Iman* constituye otra opcion robusta, manifestando en ocasiones una potencia superior. La eleccion metodologica debe fundamentarse en el diseño, el volumen muestral y la disponibilidad del software estadistico.

Para el caso de Friedman, el protocolo post hoc debe blindar la dependencia intrinseca de las mediciones, reconociendo que los mismos bloques son evaluados recurrentemente. Una estrategia convencional consiste en aplicar comparaciones de *Wilcoxon para muestras relacionadas* con correcciones de significancia. Asimismo, procedimientos como *Nemenyi* o *Conover* para rangos dependientes resultan idoneos para aislar que hitos temporales o tratamientos presentan discrepancias sistematicas una vez rechazada la hipotesis nula de igualdad global.

La implementacion de estos contrastes es vital, pues un reporte limitado al estadistico omnibus resultaria insuficiente para la toma de decisiones. En la practica educativa, constatar simplemente que existen diferencias no basta para orientar la intervencion; se requiere conocer que metodologia propicia resultados superiores. En medicina, esta precision es critica para identificar que regimen terapeutico minimiza la sintomatologia o el riesgo, permitiendo una lectura sustantiva de la eficacia clinica detectada en la fase global.

Un pilar metodologico ineludible es el **ajuste por comparaciones multiples**. Al ejecutar diversos cruces pareados, se incrementa exponencialmente el riesgo de error tipo I, es decir, de detectar falsos positivos por puro azar. Cuanto mayor sea el numero de categorias comparadas, mayor sera la probabilidad de hallar una diferencia espuria si no se aplica un criterio de decision mas riguroso. Consecuentemente, es una mala practica interpretar valores p brutos sin haber mediado una correccion que garantice la integridad de la inferencia estadistica.

Entre los protocolos de ajuste, el metodo de **Bonferroni** se erige como la opcion mas conservadora, distribuyendo el nivel de significancia entre el total de contrastes realizados. Si bien blindo eficazmente la investigacion contra errores de tipo I, su severidad puede mermar la potencia analitica, dificultando la identificacion de efectos reales. No obstante, su sencillez lo convierte en un estandar frecuente en dominios donde se exige un control estricto de la tasa de error experimental.

El procedimiento de **Holm** representa una alternativa equilibrada, pues controla el riesgo de error sin la rigidez extrema de Bonferroni. Al ordenar los valores p y aplicar umbrales progresivos, suele considerarse

una tecnica mas versatil en diversos estudios aplicados. Metodos como **Hochberg** operan bajo una logica similar, proporcionando opciones para rechazar hipotesis nulas sin comprometer excesivamente la capacidad de deteccion de la prueba.

Por su parte, la tecnica de **Benjamini-Hochberg** se orienta al control de la tasa de falsos descubrimientos. A diferencia de las correcciones previas que buscan proteger el error familiar, este enfoque permite un balance distinto entre la sensibilidad y el rigor, resultando util en escenarios con un elevado volumen de comparaciones. Su implementacion debe estar justificada por la naturaleza exploratoria o confirmatoria de los objetivos trazados por el investigador.

La seleccion del ajuste adecuado depende del nivel de cautela requerido por el contexto. En investigaciones clinicas, donde las conclusiones incorrectas acarrear repercusiones graves, se privilegian posturas conservadoras como Bonferroni u Holm. En cambio, si se busca maximizar la sensibilidad para detectar diferencias incipientes, pueden considerarse alternativas menos restrictivas. Lo fundamental es que el reporte tecnico declare con total transparencia el metodo de correccion seleccionado.

El informe de los analisis post hoc debe ser exhaustivo y no limitarse a la mencion del procedimiento. Es obligatorio detallar el ajuste implementado, los pares contrastados, la significancia corregida y la *direccion de los rangos*. En una evaluacion pedagogica, por ejemplo, el reporte debe discernir si la disparidad se localiza entre el modelo tradicional y el digital, o si se manifiesta en otros cruces, permitiendo una lectura pormenorizada de los hallazgos.

Mas alla del valor p ajustado, se recomienda reportar rangos promedio o diferencias de posicion, ya que estas metricas decodifican el sentido del resultado. Si el recurso digital exhibe una dominancia jerarquica significativa frente al metodo convencional, se confirma una tendencia hacia rendimientos superiores. Este enfoque integral supera la simple declaracion de significancia, proporcionando una base solida para la interpretacion de la superioridad relativa de una condicion sobre otra.

Asimismo, es crucial escrutar la **magnitud practica** de los hallazgos. Una diferencia estadistica puede carecer de relevancia sustantiva si no representa una mejora tangible en el aprendizaje o un beneficio clinico evidente. Por ello, el analisis de rangos debe flanquearse con tamaños de efecto y medidas descriptivas robustas. En medicina, una reduccion minima en una escala subjetiva, aunque significativa en el calculo, exige una evaluacion prudente sobre su importancia real para el bienestar del paciente.

Debe evitarse la sobreinterpretacion de los resultados post hoc. Aun con ajustes, la multiplicidad de contrastes conlleva un riesgo residual de hallazgos fortuitos. Por tanto, las conclusiones deben armonizarse con el marco teorico, el diseño y el soporte grafico. La solidez de una inferencia no emana unicamente del valor p, sino de la coherencia interna entre la evidencia estadistica y el comportamiento morfologico de los datos en estudio.

Para Kruskal-Wallis, una redaccion tecnica adecuada seria: "Ante la significancia del contraste global, se ejecuto la prueba de Dunn con ajuste de Holm. Los resultados aislaron diferencias significativas entre el metodo tradicional y el digital, manifestando este ultimo una clara propension hacia rangos superiores. No se detectaron disparidades en los demas cruces pareados". Este formato comunica con precision el metodo, el ajuste y la orientacion de los resultados detectados.

En el escenario de Friedman, el reporte podria enunciarse asi: "Tras obtener un hallazgo significativo, se procedio a comparaciones de Wilcoxon con ajuste de Bonferroni. Se identifico una divergencia entre el

hito inicial y el final, con una tendencia sistemática hacia valores más elevados en el seguimiento post-intervención. El cruce entre la fase inicial e intermedia no arrojó evidencia de diferencias significativas".

En síntesis, las pruebas post hoc no paramétricas son instrumentos indispensables cuando Kruskal-Wallis o Friedman revelan faltas de equivalencia. Su propósito es desglosar la significancia global en contrastes específicos. Mientras que en diseños independientes se opta por Dunn o Conover-Iman, en medidas repetidas se privilegian Wilcoxon pareado o Nemenyi. El ajuste por multiplicidad es un requisito sine qua non para blindar la investigación contra errores de tipo I, exigiendo un reporte transparente que integre métodos, ajustes y la dirección jerárquica de los rangos.

10. Ventajas en datos no normales

Una de las principales ventajas de Kruskal-Wallis y Friedman es que no exigen que los datos sigan una distribución normal. Esto las convierte en pruebas útiles cuando se trabaja con variables ordinales, datos asimétricos, muestras pequeñas o valores atípicos. A diferencia del ANOVA paramétrico, estas pruebas no comparan directamente medias, sino rangos, lo que reduce la influencia de datos extremos.

En medicina, por ejemplo, variables como dolor, días de hospitalización o tiempo de recuperación suelen presentar distribuciones no normales. En educación, los puntajes pueden concentrarse en ciertos rangos debido al límite de las calificaciones. En investigación social, muchas respuestas provienen de escalas tipo Likert, como niveles de satisfacción, acuerdo o percepción. En estos casos, el uso de pruebas basadas en rangos resulta más adecuado que aplicar directamente métodos paramétricos.

Otra ventaja es que sus resultados pueden explicarse de manera sencilla. Al trabajar con rangos, se puede decir que un grupo o condición tiende a ubicarse por encima o por debajo de otro. Esto facilita la interpretación para investigadores, docentes, médicos o profesionales que necesitan conclusiones prácticas.

Sin embargo, estas pruebas no deben aplicarse sin revisar el diseño del estudio. Kruskal-Wallis requiere grupos independientes, mientras que Friedman requiere mediciones repetidas o datos relacionados. Además, la variable debe poder ordenarse. Por ello, aunque son útiles para datos no normales, también tienen supuestos que deben respetarse.

En conclusión, Kruskal-Wallis y Friedman son pruebas adecuadas cuando los datos no cumplen normalidad, presentan valores extremos o provienen de escalas ordinales. Su principal fortaleza está en el uso de rangos, lo que permite realizar comparaciones más robustas y fáciles de interpretar. No obstante, deben aplicarse de acuerdo con el tipo de diseño y acompañarse de una interpretación cuidadosa.

11. Tamaño del efecto y reporte

Un informe estadístico completo no debe limitarse únicamente al valor p. Aunque el valor p permite decidir si existe evidencia estadística para rechazar la hipótesis nula, no indica qué tan importante o

grande es la diferencia encontrada. Por ello, es necesario complementar el resultado con una medida de tamaño del efecto. Esta medida ayuda a interpretar la relevancia práctica de los resultados.

En la prueba de Kruskal-Wallis, se pueden reportar medidas como épsilon cuadrado o eta cuadrado basado en el estadístico H. Estas medidas permiten aproximar la proporción de variabilidad de los rangos que puede ser explicada por el factor o grupo comparado. Por ejemplo, si se comparan tres métodos de enseñanza, el tamaño del efecto permite estimar qué tanto influye el método utilizado en las diferencias observadas en los rangos.

En la prueba de Friedman, una medida frecuente es el coeficiente W de Kendall. Este coeficiente se interpreta como una medida de concordancia o magnitud del efecto entre condiciones repetidas. Su valor permite conocer si las diferencias entre las condiciones son débiles, moderadas o fuertes. En este caso, no basta con saber que existe una diferencia significativa; también interesa saber si esa diferencia tiene importancia real dentro del contexto estudiado.

La estructura mínima de reporte debe incluir el estadístico de prueba, los grados de libertad, el valor p, el resumen descriptivo por grupo o condición, los rangos promedio, el método post hoc si corresponde y el tamaño del efecto. Además, debe declararse el nivel de significancia utilizado, por ejemplo, $\alpha = 0.05$, y el software estadístico empleado para el análisis.

Un ejemplo de redacción sería: “La prueba de Kruskal-Wallis mostró diferencias globales entre tratamientos, $H(2) = 12.80$, $p = .002$. El tratamiento B presentó el rango promedio más alto, seguido del tratamiento C y el tratamiento A. Las comparaciones post hoc con la prueba de Dunn y ajuste de Holm indicaron diferencias significativas entre A y B. El tamaño del efecto indicó una diferencia de magnitud moderada”.

En conclusión, el tamaño del efecto permite complementar la interpretación del valor p y ofrece una visión más completa del resultado. Reportarlo correctamente mejora la calidad del informe estadístico, porque permite conocer no solo si existe una diferencia, sino también qué tan relevante es en términos prácticos.

12. Limitaciones y errores frecuentes

Un error frecuente es usar Kruskal-Wallis con datos dependientes. Si los mismos sujetos se miden varias veces, se rompe la independencia entre grupos y la prueba correcta es Friedman u otro modelo para medidas repetidas.

Otro error es interpretar automáticamente un resultado significativo como diferencia de medianas sin revisar la forma de las distribuciones. Si un grupo es más disperso o asimétrico que otro, la diferencia de rangos puede reflejar cambios en la distribución completa.

También debe evitarse reportar solo ' $p < .05$ '. La decisión estadística debe ir acompañada de descripción, dirección, magnitud y relevancia práctica. En investigaciones aplicadas, una diferencia estadísticamente significativa puede ser pequeña o poco importante para la toma de decisiones.

Comparacion sintetica entre Kruskal-Wallis y Friedman

Criterio	Kruskal-Wallis	Friedman
Diseño	Grupos independientes	Medidas repetidas o bloques
Unidad de rango	Todas las observaciones juntas	Observaciones dentro de cada bloque
Equivalente parametrico	ANOVA de un factor independiente	ANOVA de medidas repetidas
Resultado global	H aproximado a chi-cuadrado	Q aproximado a chi-cuadrado
Post hoc habitual	Dunn, Mann-Whitney pareado con ajuste, Conover	Wilcoxon pareado con ajuste, Nemenyi, Conover

Aplicaciones practicas o ejemplos

Medicina: comparacion de tratamientos analgesicos

En estudios clinicos, la intensidad de dolor suele medirse con escalas ordinales de 0 a 10. Aunque se registre numericamente, no siempre es razonable asumir normalidad. Kruskal-Wallis permite comparar tres tratamientos analgesicos aplicados a pacientes independientes.

El investigador puede reportar medianas, rangos intercuartiles y rangos promedio por grupo. Si el resultado global es significativo, se aplican comparaciones post hoc para identificar que tratamientos difieren. La conclusion debe conectarse con relevancia clinica: una diferencia estadistica puede no ser suficiente si el cambio no supera un umbral de mejoría percibida por el paciente.

Medicina: seguimiento del mismo paciente

Friedman es apropiada cuando el mismo paciente es evaluado en tres momentos, por ejemplo antes del tratamiento, despues de dos semanas y despues de un mes. Cada paciente funciona como bloque, y los rangos se calculan dentro de su trayectoria.

La ventaja es controlar la heterogeneidad individual. Pacientes con niveles de dolor basal muy diferentes pueden compararse porque el interes esta en el cambio relativo entre momentos dentro de cada paciente.

Medicina: biomarcadores con asimetria

Variables como concentracion de proteina C reactiva, dias de hospitalizacion o carga viral pueden presentar distribuciones asimetricas. Si se comparan tres grupos diagnosticos independientes, Kruskal-Wallis resulta una opcion razonable.

El analisis debe acompanarse de graficos y medidas robustas. La transformacion a rangos reduce el efecto de valores extremos, pero no reemplaza la revision de calidad de datos ni la interpretacion clinica.

Educacion: estrategias de ensenanza independientes

En una investigacion educativa se pueden comparar tres aulas que recibieron estrategias diferentes: clase expositiva, aprendizaje basado en problemas y recurso digital. Si los estudiantes pertenecen a aulas distintas, el disenio es independiente y corresponde Kruskal-Wallis.

La conclusion se formula en terminos de tendencia de puntajes. Si el recurso digital presenta mayor rango promedio, se podria afirmar que los estudiantes de esa estrategia tienden a obtener puntajes superiores, sujeto a control de sesgos de asignacion.

Educacion: mismos estudiantes bajo varios metodos

Si los mismos estudiantes resuelven pruebas despues de tres metodos aplicados en secuencia controlada, el diseno es repetido. Friedman compara los metodos dentro de cada estudiante y evita que las diferencias de habilidad general entre alumnos dominen el resultado.

Este caso es especialmente util en estudios piloto, donde el tamano muestral puede ser limitado y los puntajes no siguen una distribucion normal.

Educacion: rubricas ordinales

Las rubricas de desempeno producen categorias como inicial, en proceso, logrado y destacado. Esas categorias son ordinales y no deben tratarse automaticamente como intervalos perfectos. Las pruebas por rangos permiten una lectura mas compatible con la naturaleza de la medicion.

Kruskal-Wallis compararia grupos independientes; Friedman compararia desempenos de los mismos estudiantes en varias tareas o momentos.

Investigacion social: satisfaccion ciudadana

Las encuestas de satisfaccion usan con frecuencia escalas Likert. Para comparar satisfaccion entre tres distritos, niveles socioeconomicos o tipos de servicio, Kruskal-Wallis permite analizar si las respuestas tienden a diferir sin imponer normalidad.

El resultado debe contextualizarse con distribuciones de frecuencia. En escalas ordinales, la mediana y los porcentajes por categoria suelen comunicar mejor que la media.

Investigacion social: panel de percepciones

Friedman se aplica cuando los mismos participantes califican varias instituciones, politicas publicas o mensajes. Cada participante constituye un bloque y se analizan los rangos asignados a cada alternativa.

Esta estrategia reduce el sesgo por severidad o benevolencia individual: una persona que califica todo bajo o todo alto no altera tanto la comparacion relativa entre alternativas.

Investigacion social: evaluacion de programas

En programas sociales pueden compararse resultados ordinales entre modalidades de intervencion. Si los participantes pertenecen a grupos separados, Kruskal-Wallis permite evaluar diferencias globales. Si los mismos participantes se evaludan antes, durante y despues, Friedman es mas coherente.

La utilidad aplicada reside en tomar decisiones sobre continuidad, ajuste o escalamiento del programa con evidencia resistente a distribuciones no normales.

Ejemplo resuelto de Kruskal-Wallis

Se simularon puntajes de mejoría clínica para tres tratamientos independientes. El estadístico obtenido fue $H = 16.23$, con valor p aproximado $= 0.0003$. Con $\alpha = .05$, se rechaza la hipótesis nula global.

Los rangos promedio indican la dirección: Tratamiento B tiene el rango promedio más alto, Tratamiento C ocupa una posición intermedia y Tratamiento A la menor. El resultado sugiere que al menos un tratamiento difiere en la distribución de mejoría. Para identificar pares específicos se recomienda una prueba post hoc de Dunn con ajuste de Holm o Bonferroni.

Grupo	n	Mediana	Rango promedio
Tratamiento A	8	14.0	6.12
Tratamiento B	8	19.5	20.19
Tratamiento C	8	15.5	11.19

Ejemplo resuelto de Friedman

Se simularon puntajes de diez estudiantes evaluados bajo tres métodos. El estadístico de Friedman fue $Q = 20.00$, con valor p aproximado $= 0.0000$. Con $\alpha = .05$, se rechaza la hipótesis nula de igualdad entre métodos.

El método digital acumuló el mayor rango promedio, seguido del método con práctica y del método tradicional. La conclusión es que las condiciones no son equivalentes y que el método digital tiende a ubicarse por encima dentro de los mismos estudiantes. Deben aplicarse comparaciones pareadas de Wilcoxon con ajuste por múltiples pruebas para confirmar los pares.

Método	Suma de rangos	Rango promedio
Método tradicional	10.0	1.00
Método con práctica	20.0	2.00
Método digital	30.0	3.00

Guía de decisión rápida

Si los grupos son diferentes personas o unidades y cada observación aparece una sola vez, use Kruskal-Wallis. Si las mismas personas o unidades aparecen en todas las condiciones, use Friedman. Si solo hay dos grupos independientes, considere Mann-Whitney; si solo hay dos mediciones repetidas, considere Wilcoxon de rangos con signo.

La pregunta clave no es solo cuántas condiciones hay, sino si las observaciones son independientes o dependientes. Esa decisión define la prueba antes que cualquier cálculo.

Buenas prácticas de reporte aplicado

Un reporte aplicado debe presentar tabla descriptiva, gráfico, prueba global, post hoc si procede, tamaño de efecto y conclusión sustantiva. La conclusión debe hablar en el lenguaje del problema: pacientes, estudiantes, ciudadanos, programas o intervenciones.

También se debe declarar por qué se eligió una prueba no paramétrica: escala ordinal, no normalidad, outliers, tamaño pequeño o incumplimiento de supuestos del ANOVA.

Riesgos de interpretacion en aplicaciones

Las pruebas no parametricas no eliminan sesgos de muestreo, confundidores ni problemas de diseno. Un resultado significativo puede deberse a diferencias previas entre grupos si no hubo asignacion adecuada.

Por ello, en aplicaciones medicas, educativas y sociales, el analisis estadistico debe acompanarse de criterio metodologico, revision del diseno y transparencia en limitaciones.

Cierre aplicado

Kruskal-Wallis y Friedman son herramientas versatiles porque se adaptan a datos reales con restricciones practicas. Permiten comparar mas de dos condiciones sin depender de normalidad estricta y ofrecen una lectura intuitiva mediante rangos.

Su mayor valor aparece cuando se usan con disciplina: prueba correcta segun diseno, rangos bien interpretados, post hoc ajustado y conclusiones conectadas con la relevancia practica.

Ejercicio o caso aplicado por integrante (Mary)

Caso aplicado: comparación no paramétrica del tiempo de desarrollo por lenguaje y de bugs detectados por IDE.

Caso de estudio. Se diseñó una base de datos con fines académicos para analizar el rendimiento de diferentes lenguajes de programación en la implementación del algoritmo de Dijkstra. El análisis estadístico fue realizado en IBM SPSS Statistics utilizando pruebas no paramétricas debido a que los datos no cumplieron el supuesto de normalidad.

En esta sección se documenta el analisis practico realizado en IBM SPSS. Primero se aplico Kruskal-Wallis para comparar tres grupos independientes (Python, Java y C++). Luego se aplico Friedman para comparar tres mediciones relacionadas del mismo grupo de programadores (VS Code, IntelliJ y Eclipse). Se reportan las capturas clave, los valores estadisticos y la interpretacion.

1. Prueba de Kruskal-Wallis

Objetivo: determinar si el tiempo de desarrollo del algoritmo de Dijkstra difiere significativamente entre los lenguajes Python, Java y C++.

Variable dependiente: Tiempo Desarrollo _Min. Variable de agrupacion: Lenguaje. Tamano muestral: 450 observaciones, distribuidas en 150 casos por cada lenguaje.

Antes de aplicar la prueba se reviso la normalidad por grupo. En SPSS, la prueba de Shapiro-Wilk arrojo Sig. = .000 para Python, Java y C++, por lo que se reporta como $p < .001$. Esto indica que no se cumple el supuesto de normalidad y justifica el uso de una prueba no parametrica.

Pruebas de normalidad							
Lenguaje	Kolmogorov-Smirnov ^a			Shapiro-Wilk			Sig.
	Estadístico	gl	Sig.	Estadístico	gl	Sig.	
Tiempo_Desarrollo_Min							
Python	,115	150	,000	,916	150	,000	
Java	,103	150	,001	,937	150	,000	
C++	,120	150	,000	,912	150	,000	

a. Corrección de la significación de Lilliefors

Figura 1. Pruebas de normalidad por lenguaje.

Hipotesis: H0 = no existen diferencias significativas en el tiempo de desarrollo entre los tres lenguajes.
H1 = al menos un lenguaje presenta una distribución de tiempos diferente.

Rangos			
Lenguaje		N	Rango promedio
Tiempo_Desarrollo_Min	Python	150	216,36
	Java	150	277,25
	C++	150	182,89
	Total	450	

Estadísticos de contraste ^{a,b}	
	Tiempo_Desarrollo_Min
Chi-cuadrado	40,600
gl	2
Sig. asintót.	,000

a. Prueba de Kruskal-Wallis

b. Variable de agrupación: Lenguaje

Figura 2. Rangos y estadísticos de contraste de Kruskal-Wallis.

Epsilon cuadrado aproximado

0.086

Decision: como $p < 0.05$, se rechaza la hipótesis nula . Existen diferencias estadísticamente significativas en el tiempo de desarrollo entre los lenguajes. Java obtuvo el mayor rango promedio, seguido de Python, mientras que C++ presento el menor rango promedio.

Post hoc de Kruskal-Wallis: U de Mann-Whitney

Como el contraste global fue significativo, se realizaron comparaciones por pares mediante U de Mann-Whitney. Se aplico corrección de Bonferroni: $\alpha \text{ ajustado} = .05 / 3 = .0167$.

Comparacion	U	Z	Sig.	Decision con Bonferroni
Python vs Java	8068.000	-4.236	,000	Significativa
Python vs C++	9439.000	-2.411	,016	Significativa al limite
Java vs C++	6669.500	-6.097	,000	Significativa

Tabla 2. Comparaciones post hoc para Kruskal-Wallis.

	Lenguaje	N	Rango promedio	Suma de rangos
Tiempo_Desarrollo_Min	Python	150	129,29	19393,00
	Java	150	171,71	25757,00
	Total	300		

Estadísticos de contraste ^a	
	Tiempo_Desarrollo_Min
U de Mann-Whitney	8068,000
W de Wilcoxon	19393,000
Z	-4,236
Sig. asintót. (bilateral)	,000

a. Variable de agrupación:
Lenguaje

Figura 3. Post hoc Python vs Java.

	Lenguaje	N	Rango promedio	Suma de rangos
Tiempo_Desarrollo_Min	Python	150	162,57	24386,00
	C++	150	138,43	20764,00
	Total	300		

Estadísticos de contraste ^a	
	Tiempo_Desarrollo_Min
U de Mann-Whitney	9439,000
W de Wilcoxon	20764,000
Z	-2,411
Sig. asintót. (bilateral)	,016

Figura 4. Post hoc Python vs C++.

	Lenguaje	N	Rango promedio	Suma de rangos
Tiempo_Desarrollo_Min	Java	150	181,04	27155,50
	C++	150	119,96	17994,50
	Total	300		

Estadísticos de contraste ^a	
	Tiempo_Desarrollo_Min
U de Mann-Whitney	6669,500
W de Wilcoxon	17994,500
Z	-6,097
Sig. asintót. (bilateral)	,000

Figura 5. Post hoc Java vs C++.

Interpretación del post hoc: los tres pares presentan diferencias significativas con el criterio ajustado. Por tanto, no solo existe una diferencia global, sino que los tres lenguajes difieren entre si. El orden práctico de mayor a menor tiempo de desarrollo es Java, Python y C++.

2. Prueba de Friedman

Objetivo: comparar la cantidad de bugs detectados por los mismos 150 programadores al utilizar tres IDEs: VS Code, IntelliJ y Eclipse. En este caso las mediciones son relacionadas porque cada programador fue evaluado en las tres condiciones.

Hipotesis: H0 = no existen diferencias significativas en la cantidad de bugs entre los tres IDEs. H1 = al menos un IDE difiere significativamente.

	Rango promedio
Bugs_VSCode	1,87
Bugs_IntelliJ	1,54
Bugs_Eclipse	2,59

Estadísticos de contraste^a

N	150
Chi-cuadrado	95,142
gl	2
Sig. asintót.	,000

Figura 6. Rangos y estadísticos de contraste de Friedman.

IDE	Rango promedio
VS Code	1.87
IntelliJ	1.54
Eclipse	2.59
Estadístico	Valor
N	150
Chi-cuadrado de Friedman	95.142
gl	2
Sig. asintótica	.000 ($p < .001$)
W de Kendall	0.317

Decision: como $p < .05$, se rechaza H0. Existen diferencias significativas entre los IDEs. IntelliJ presento el menor rango promedio, VS Code quedo en una posición intermedia y Eclipse presento el mayor rango promedio.

Post hoc de Friedman: Wilcoxon pareado

Debido a que Friedman fue significativo, se aplicaron comparaciones por pares con la prueba de rangos con signo de Wilcoxon. Tambien se uso Bonferroni, con alfa ajustado = .0167.

Comparacion	Z	Sig.	Decision con Bonferroni
IntelliJ vs VS Code	-3.239	.001	Significativa
Eclipse vs VS Code	-6.624	.000	Significativa
Eclipse vs IntelliJ	-8.606	.000	Significativa

Tabla 3. Comparaciones post hoc para Friedman.

		N	Rango promedio	Suma de rangos
Bugs_IntelliJ - Bugs_VSCode	Rangos negativos	80 ^a	66,53	5322,00
	Rangos positivos	46 ^b	58,24	2679,00
	Empates	24 ^c		
	Total	150		

a. Bugs_IntelliJ < Bugs_VSCode

b. Bugs_IntelliJ > Bugs_VSCode

c. Bugs_IntelliJ = Bugs_VSCode

Estadísticos de contraste^a

	Bugs_IntelliJ - Bugs_VSCode
Z	-3,239 ^b
Sig. asintót. (bilateral)	,001

Figura 7. Wilcoxon: IntelliJ vs VS Code.

Rangos				
		N	Rango promedio	Suma de rangos
Bugs_Eclipse - Bugs_VSCode	Rangos negativos	31 ^a	52,19	1618,00
	Rangos positivos	105 ^b	73,31	7698,00
	Empates	14 ^c		
	Total	150		

a. Bugs_Eclipse < Bugs_VSCode
b. Bugs_Eclipse > Bugs_VSCode
c. Bugs_Eclipse = Bugs_VSCode

Estadísticos de contraste^a

	Bugs_Eclipse - Bugs_VSCode
Z	-6,624 ^b
Sig. asintót. (bilateral)	,000

Figura 8. Wilcoxon: Eclipse vs VS Code.

Rangos				
		N	Rango promedio	Suma de rangos
Bugs_Eclipse - Bugs_IntelliJ	Rangos negativos	18 ^a	44,89	808,00
	Rangos positivos	122 ^b	74,28	9062,00
	Empates	10 ^c		
	Total	150		

a. Bugs_Eclipse < Bugs_IntelliJ
 b. Bugs_Eclipse > Bugs_IntelliJ
 c. Bugs_Eclipse = Bugs_IntelliJ

Estadísticos de contraste ^a	
	Bugs_Eclipse - Bugs_IntelliJ
Z	-8,606 ^b
Sig. asintót. (bilateral)	,000

a. Prueba de los rangos con signo de Wilcoxon

Figura 9. Wilcoxon: Eclipse vs IntelliJ.

Interpretación del post hoc: las tres comparaciones fueron significativas. El orden final indica que IntelliJ tuvo menor cantidad de bugs, VS Code se ubicó en un nivel intermedio y Eclipse presentó la mayor cantidad de bugs detectados.

Conclusión del caso aplicado

El caso aplicado evidencia el uso correcto de dos pruebas no paramétricas según el tipo de diseño. Kruskal-Wallis permitió comparar grupos independientes de lenguajes de programación, mientras que Friedman permitió comparar condiciones relacionadas medidas en los mismos programadores. En ambos análisis se obtuvieron resultados significativos y se completaron las comparaciones post hoc correspondientes con ajuste de Bonferroni.

Conclusiones

5. Kruskal-Wallis y Friedman son alternativas no paramétricas al ANOVA cuando la variable es ordinal, no normal o presenta valores extremos que comprometen la comparación de medias.
6. La diferencia central entre ambas pruebas es el diseño: Kruskal-Wallis compara grupos independientes, mientras Friedman compara condiciones repetidas o bloques relacionados.
7. La interpretación debe centrarse en rangos promedio, distribuciones y dirección de las diferencias, evitando afirmar diferencias de medias cuando el análisis se realizó sobre rangos.
8. Un resultado global significativo exige pruebas post hoc no paramétricas con ajuste por múltiples comparaciones para identificar los pares responsables de la diferencia.
9. En medicina, educación e investigación social, estas pruebas son valiosas porque se adaptan a escalas ordinales, muestras pequeñas y datos reales que rara vez cumplen todos los supuestos paramétricos.

Recomendaciones

10. Verificar primero el diseño del estudio para elegir entre grupos independientes y medidas repetidas.
11. Reportar mediana, rango intercuartil, rangos promedio, estadístico, grados de libertad, valor p y tamaño de efecto.
12. Usar pruebas post hoc adecuadas: Dunn o Mann-Whitney ajustado para Kruskal-Wallis; Wilcoxon pareado, Nemenyi o Conover para Friedman.
13. No sustituir la revisión metodológica por una prueba no paramétrica; deben evaluarse sesgos, independencia, datos faltantes y pertinencia de la escala.
14. Acompañar los resultados con gráficos simples como boxplots, diagramas de puntos o tablas de frecuencias para mejorar la interpretación aplicada.

Referencias bibliográficas

- Conover, W. J. (1999). Practical nonparametric statistics (3rd ed.). Wiley.
- Demsar, J. (2006). Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, 7, 1-30.
- Dunn, O. J. (1964). Multiple comparisons using rank sums. *Technometrics*, 6(3), 241-252.
- Friedman, M. (1937). The use of ranks to avoid the assumption of normality implicit in the analysis of variance. *Journal of the American Statistical Association*, 32(200), 675-701.
- Hollander, M., Wolfe, D. A., & Chicken, E. (2014). *Nonparametric statistical methods* (3rd ed.). Wiley.
- Kruskal, W. H., & Wallis, W. A. (1952). Use of ranks in one-criterion variance analysis. *Journal of the American Statistical Association*, 47(260), 583-621.
- R Core Team. (2026). `kruskal.test`: Kruskal-Wallis rank sum test. R Documentation. <https://stat.ethz.ch/R-manual/R-devel/library/stats/html/kruskal.test.html>
- R Core Team. (2026). `friedman.test`: Friedman rank sum test. R Documentation. <https://stat.ethz.ch/R-manual/R-devel/library/stats/html/friedman.test.html>
- SciPy Developers. (2026). `scipy.stats.kruskal`. SciPy v1.18.0 Manual. <https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.kruskal.html>
- SciPy Developers. (2026). `scipy.stats.friedmanchisquare`. SciPy v1.18.0 Manual. <https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.friedmanchisquare.html>
- Siegel, S., & Castellan, N. J. (1988). *Nonparametric statistics for the behavioral sciences* (2nd ed.). McGraw-Hill.

Anexo: data utilizada

A. Datos para Kruskal-Wallis

Grupo	Caso	Puntaje
Tratamiento A	1	12
Tratamiento A	2	15
Tratamiento A	3	14
Tratamiento A	4	13
Tratamiento A	5	16
Tratamiento A	6	14
Tratamiento A	7	15
Tratamiento A	8	13
Tratamiento B	1	18
Tratamiento B	2	20
Tratamiento B	3	19
Tratamiento B	4	17
Tratamiento B	5	21
Tratamiento B	6	20
Tratamiento B	7	18
Tratamiento B	8	22
Tratamiento C	1	14
Tratamiento C	2	16
Tratamiento C	3	15
Tratamiento C	4	15
Tratamiento C	5	17
Tratamiento C	6	16
Tratamiento C	7	14
Tratamiento C	8	18

B. Datos para Friedman

Estudiante	Metodo tradicional	Metodo con practica	Metodo digital
E1	12	14	16
E2	13	15	17
E3	11	13	15
E4	14	15	18
E5	12	14	16
E6	10	13	15
E7	13	15	17
E8	11	14	16
E9	12	13	15
E10	14	16	18

C. Resumen de resultados calculados

Prueba	Estadistico	gl	p aproximado	Decision con alfa = .05
Kruskal-Wallis	H = 16.23	2	0.0003	Rechazar H0
Friedman	Q = 20.00	2	0.0000	Rechazar H0