

ESTADÍSTICA NO PARAMÉTRICA

# Kruskal-Wallis y Friedman

*Pruebas no paramétricas aplicadas a la comparación de métodos de enseñanza*

---

## INTEGRANTES

- Erick Mijael Delgado Lima
- Julio Rodrigo Zegarra Muñoz
- Mary Margoth Mamani Quispe

# Introducción

En investigación educativa es común comparar métodos de enseñanza para saber cuál genera mejores resultados. Sin embargo, muchos datos reales (encuestas, calificaciones ordinales, muestras pequeñas) no cumplen los supuestos de normalidad que exige la estadística clásica.

Para estos casos existen las pruebas no paramétricas, un conjunto de métodos estadísticos que no dependen de una distribución específica de los datos.



## Idea clave

Cuando los datos no son normales o son ordinales, comparar promedios pierde sentido: comparamos rangos.

# Objetivos de la presentación

01



## Comprender los conceptos

Diferenciar pruebas paramétricas y no paramétricas y saber cuándo aplicarlas.

02



## Interpretar rangos

Entender cómo se ordenan y comparan los datos mediante rangos.

03



## Dominar Kruskal-Wallis y Friedman

Reconocer sus hipótesis, condiciones de uso y forma de interpretación.

04



## Aplicar a un caso real

Comparar tres métodos de enseñanza usando ambas pruebas.

# ¿Qué son las pruebas paramétricas y no paramétricas?



## Pruebas paramétricas

- Asumen que los datos siguen una distribución normal.
- Trabajan con medias y varianzas.
- Ejemplo: ANOVA, prueba t.
- Requieren escalas de intervalo o razón.



## Pruebas no paramétricas

- No requieren normalidad en los datos.
- Trabajan con rangos u orden de los datos.
- Ejemplo: Kruskal-Wallis, Friedman.
- Útiles con muestras pequeñas o datos ordinales.

Las **pruebas paramétricas** comparan datos usando supuestos como normalidad y medias, mientras que las **no paramétricas** no requieren normalidad estricta y suelen comparar rangos o posiciones de los datos.

## Alternativa no paramétrica al ANOVA

El ANOVA de un factor compara las medias de tres o más grupos, pero exige normalidad y homogeneidad de varianzas. Cuando estos supuestos no se cumplen, se recurre a su alternativa no paramétrica.



*Kruskal-Wallis conserva la lógica de comparar varios grupos, pero reemplaza las medias por los rangos promedio de cada grupo, evitando el supuesto de normalidad.*

# Concepto de rangos en estadística no paramétrica

Un rango es la posición que ocupa un dato al ordenar todos los valores de menor a mayor. En lugar de analizar los valores originales, las pruebas no paramétricas analizan estas posiciones.

- Se ordenan todos los datos de menor a mayor.
- Se asigna el rango 1 al valor más pequeño.
- Si hay empates, se promedian los rangos.
- Se trabaja con la suma de rangos por grupo.

| Dato | Valor | Rango |
|------|-------|-------|
| A    | 12    | 2     |
| B    | 9     | 1     |
| C    | 15    | 3.5   |
| D    | 15    | 3.5   |
| E    | 20    | 5     |

*Nota: los valores 15 y 15 empatan → ambos reciben el rango promedio (3.5), en vez de 3 y 4.*

# Prueba de Kruskal-Wallis

Es la alternativa no paramétrica al ANOVA de un factor. **Permite comparar tres o más grupos independientes para determinar si provienen de poblaciones con la misma distribución.**

## Fórmula del estadístico H

$$H = \left[ \frac{12}{N(N+1)} \right] \times \sum \left( \frac{R_i^2}{n_i} \right) - \frac{3(N+1)}{2}$$

*N: total de datos · n<sub>i</sub>: tamaño del grupo i · R<sub>i</sub>: suma de rangos del grupo i.*

*En palabras: compara la suma de rangos de cada grupo; si son muy distintas, los grupos difieren.*



## Idea central

- Se ordenan TODOS los datos juntos (sin importar el grupo).
- Se asigna un rango a cada dato.
- Se suman los rangos por grupo.
- Se calcula el estadístico H.

Kruskal, W. H., & Wallis, W. A. (1952). *Use of ranks in one-criterion variance analysis*. Journal of the American Statistical Association, 47(260), 583–621.

## ¿Cuándo se usa Kruskal-Wallis?



### Grupos independientes

Se comparan tres o más grupos distintos de sujetos (no los mismos individuos).



### Datos no normales

La variable no cumple el supuesto de normalidad.



### Escala ordinal o continua

Aplica a datos ordinales o de intervalo/razón sin normalidad.



### Muestras pequeñas

Ideal cuando el tamaño muestral es reducido para confiar en el ANOVA.



### Ejemplo educativo

Tres grupos distintos de estudiantes, cada uno enseñado con un método diferente (tradicional, virtual, colaborativo), evaluados una sola vez.

---

*Como son estudiantes diferentes en cada grupo → se usa Kruskal-Wallis.*

Compara tres o más grupos independientes para determinar si provienen de la misma distribución o si al menos uno difiere significativamente.



# Hipótesis e interpretación de Kruskal-Wallis

## $H_0$ (Hipótesis nula)

Las medianas de todos los grupos son iguales (no hay diferencias entre métodos).

## $H_1$ (Hipótesis alterna)

Al menos una mediana es diferente de las demás.



## Regla de decisión

- Si  $p \leq 0.05 \rightarrow$  se rechaza  $H_0$ : existen diferencias significativas entre grupos.
- Si  $p > 0.05 \rightarrow$  no se rechaza  $H_0$ : no hay evidencia de diferencias.

*El estadístico  $H$  se compara con la distribución chi-cuadrado ( $\chi^2$ ) con  $k-1$  grados de libertad, donde  $k$  es el número de grupos.*

**Conover, W. J. (1999). *Practical nonparametric statistics*.**

Sirve para fundamentar la lógica de pruebas no paramétricas, hipótesis nula, valor  $p$  y decisión estadística.

# Prueba de Friedman

Es la alternativa no paramétrica al ANOVA de medidas repetidas.  
**Se usa cuando los mismos sujetos son evaluados bajo tres o más condiciones o tratamientos distintos.**

## Fórmula del estadístico $\chi^2_r$

$$\chi^2_r = \left[ \frac{12}{n k (k+1)} \right] \times \sum R_j^2 - \frac{3n (k+1)}$$

*n*: número de sujetos · *k*: número de condiciones ·  $R_j$ : suma de rangos de la condición *j*.  
 En palabras: dentro de cada sujeto se ordenan sus condiciones y luego se comparan los rangos entre condiciones.



## Idea central

- Cada sujeto pasa por todas las condiciones.
- Se rangea cada sujeto entre sus propias condiciones.
- Se suman los rangos por condición (columna).
- Se calcula el estadístico  $\chi^2_r$ .

Friedman, M. (1937). *The use of ranks to avoid the assumption of normality implicit in the analysis of variance*. Journal of the American Statistical Association, 32(200), 675–701.

Esa es la fuente original de la **prueba de Friedman**, porque Milton Friedman propuso el uso de rangos para evitar el supuesto de normalidad en diseños relacionados o de medidas repetidas.

# ¿Cuándo se usa Friedman?



## Medidas repetidas

Los mismos sujetos son evaluados en varias condiciones o momentos.



## Datos no normales

No se cumple el supuesto de normalidad de las diferencias.



## Escala ordinal o continua

Aplica a datos ordinales o continuos sin normalidad.



## Diseño de bloques

Cada sujeto actúa como su propio control (bloque).



## Ejemplo educativo

Los mismos estudiantes son evaluados tres veces: una con método tradicional, otra con virtual y otra con colaborativo.

---

*Como son los mismos estudiantes en los tres métodos → se usa Friedman.*

**Friedman se usa cuando los mismos sujetos son evaluados en tres o más condiciones relacionadas y los datos no cumplen normalidad o son ordinales.**

# Hipótesis e interpretación de Friedman

## $H_0$ (Hipótesis nula)

No hay diferencias entre las condiciones evaluadas (los métodos rinden igual).

## $H_1$ (Hipótesis alterna)

Al menos una condición difiere significativamente de las demás.



## Regla de decisión

- Si  $p \leq 0.05 \rightarrow$  se rechaza  $H_0$ : al menos un método difiere de los demás.
- Si  $p > 0.05 \rightarrow$  no se rechaza  $H_0$ : los métodos no muestran diferencias.

*El estadístico  $\chi^2_r$  también se compara con la distribución chi-cuadrado, con  $k-1$  grados de libertad ( $k$  = número de condiciones).*

**Friedman, M. (1937). *The use of ranks to avoid the assumption of normality implicit in the analysis of variance*. Journal of the American Statistical Association, 32(200), 675–701.**

Porque ahí se fundamenta la **prueba de Friedman**, el uso de **rangos** y la comparación de condiciones relacionadas.

# Diferencias entre Kruskal-Wallis y Friedman

| Criterio              | Kruskal-Wallis                  | Friedman                      |
|-----------------------|---------------------------------|-------------------------------|
| Tipo de grupos        | Independientes                  | Relacionados (mismos sujetos) |
| Alternativa a         | ANOVA de un factor              | ANOVA de medidas repetidas    |
| Forma de rangueo      | Rango de todos los datos juntos | Rango dentro de cada sujeto   |
| Número de mediciones  | Una por sujeto                  | Varias por sujeto (repetidas) |
| Estadístico de prueba | H (chi-cuadrado)                | $\chi^2_r$ (chi-cuadrado)     |
| Ejemplo típico        | 3 grupos distintos de alumnos   | Mismos alumnos, 3 métodos     |

Kruskal-Wallis se usa para comparar grupos independientes, mientras que Friedman se usa para comparar las mismas personas o sujetos evaluados en varias condiciones.

# Pruebas post hoc no paramétricas

Cuando Kruskal-Wallis o Friedman detectan diferencias significativas, no indican entre qué grupos específicos ocurren. Para ello se aplican pruebas post hoc.



## Prueba de Dunn

Comparaciones múltiples por pares tras Kruskal-Wallis, con ajuste (p. ej. Bonferroni).



## Wilcoxon con Bonferroni

Comparaciones por pares tras Friedman, ajustando el nivel de significancia.



## Nemenyi

Alternativa post hoc para comparar todos los pares tras Friedman.

*Importante: estas pruebas evitan el error de comparar múltiples pares sin control, que aumentaría la probabilidad de falsos positivos.*

Las pruebas post hoc sirven para identificar exactamente entre qué grupos o condiciones están las diferencias después de que Kruskal-Wallis o Friedman detectan una diferencia general.

# Aplicaciones prácticas



## Medicina

Comparar la eficacia de tratamientos cuando los resultados clínicos no son normales, o el mismo paciente prueba varios tratamientos.



## Educación

Comparar métodos de enseñanza, calificaciones ordinales o percepciones de estudiantes.



## Investigación social

Comparar percepciones, satisfacción o actitudes medidas en escalas tipo Likert.

# Comparación de tres métodos de enseñanza

Método A: tradicional • Método B: virtual • Método C: colaborativo



## Escenario 1: grupos diferentes

Tres grupos distintos de estudiantes, cada uno con un método → Kruskal-Wallis.



## Escenario 2: mismos estudiantes

Los mismos estudiantes evaluados con los tres métodos → Friedman.

| Estudiante | Método A | Método B | Método C |
|------------|----------|----------|----------|
| 1          | 12       | 15       | 18       |
| 2          | 10       | 14       | 16       |
| 3          | 13       | 16       | 19       |
| 4          | 11       | 13       | 17       |

Datos ficticios: puntaje de comprensión (0-20) de 4 estudiantes con los tres métodos.

- $H_0$ : los tres métodos producen resultados similares.
- $H_1$ : al menos un método difiere.
- Valor p referencial: 0.021
- Como  $p < 0.05 \rightarrow$  se rechaza  $H_0$ .



## Mi análisis usa dos diseños no paramétricos

**450 casos**

Kruskal-Wallis

**150 c/u**

Por lenguaje

**150**

Mismos programadores

**0.05**

Nivel de alfa

La primera base compara lenguajes de programación con grupos independientes. La segunda compara IDEs en los mismos programadores, por eso requiere Friedman.

## 08 · VALIDACIÓN PREVIA

## La normalidad no se cumple en los tres lenguajes

Pruebas de normalidad

|                       | Lenguaje | Kolmogorov-Smirnov <sup>a</sup> |     |      | Shapiro-Wilk |     |      |
|-----------------------|----------|---------------------------------|-----|------|--------------|-----|------|
|                       |          | Estadístico                     | gl  | Sig. | Estadístico  | gl  | Sig. |
| Tiempo_Desarrollo_Min | Python   | ,115                            | 150 | ,000 | ,916         | 150 | ,000 |
|                       | Java     | ,103                            | 150 | ,001 | ,937         | 150 | ,000 |
|                       | C++      | ,120                            | 150 | ,000 | ,912         | 150 | ,000 |

a. Corrección de la significación de Lilliefors

### Variables principales

- Tiempo\_Desarrollo\_Min por lenguaje
- Bugs\_VSCode, Bugs\_IntelliJ y Bugs\_Eclipse
- Se interpretan rangos y valor p

### Lectura del resultado

Shapiro-Wilk muestra Sig. = .000 para Python, Java y C++.

En el informe se redacta como  $p < .001$ . Esto justifica usar Kruskal-Wallis en lugar de ANOVA.

Decisión: prueba no paramétrica

# Kruskal-Wallis detecta diferencias entre lenguajes

| Rangos                |          |     |                |
|-----------------------|----------|-----|----------------|
|                       | Lenguaje | N   | Rango promedio |
| Tiempo_Desarrollo_Min | Python   | 150 | 216,36         |
|                       | Java     | 150 | 277,25         |
|                       | C++      | 150 | 182,89         |
|                       | Total    | 450 |                |

Estadísticos de contraste<sup>a,b</sup>

|               | Tiempo_Desarrollo_Min |
|---------------|-----------------------|
| Chi-cuadrado  | 40,600                |
| gl            | 2                     |
| Sig. asintót. | ,000                  |

a. Prueba de Kruskal-Wallis

b. Variable de agrupación: Lenguaje

40.600

H de Kruskal-Wallis

2

Grados de libertad

p &lt; .001

Significancia

 $\epsilon^2 \approx .086$ 

Tamaño del efecto

Se rechaza  $H_0$ . Existen diferencias significativas en el tiempo de desarrollo entre al menos dos lenguajes.

## Los rangos ubican a Java con mayor tiempo de desarrollo

Java

277.25

mayor rango promedio

Python

216.36

posición intermedia

C++

182.89

menor tiempo relativo

Orden práctico: Java &gt; Python &gt; C++

# Las comparaciones por pares confirman diferencias

|                       | Lenguaje | N   | Rango promedio | Suma de rangos |
|-----------------------|----------|-----|----------------|----------------|
| Tiempo_Desarrollo_Min | Python   | 150 | 129,29         | 19393,00       |
|                       | Java     | 150 | 171,71         | 25757,00       |
|                       | Total    | 300 |                |                |

Estadísticos de contraste<sup>a</sup>

|                           | Tiempo_Desarrollo_Min |
|---------------------------|-----------------------|
| U de Mann-Whitney         | 8068,000              |
| W de Wilcoxon             | 19393,000             |
| Z                         | -4,236                |
| Sig. asintót. (bilateral) | ,000                  |

a. Variable de agrupación:  
Lenguaje

**Python vs Java**  
**U = 8068.000 · p < .001**

|                       | Lenguaje | N   | Rango promedio | Suma de rangos |
|-----------------------|----------|-----|----------------|----------------|
| Tiempo_Desarrollo_Min | Python   | 150 | 162,57         | 24386,00       |
|                       | C++      | 150 | 138,43         | 20764,00       |
|                       | Total    | 300 |                |                |

Estadísticos de contraste<sup>a</sup>

|                           | Tiempo_Desarrollo_Min |
|---------------------------|-----------------------|
| U de Mann-Whitney         | 9439,000              |
| W de Wilcoxon             | 20764,000             |
| Z                         | -2,411                |
| Sig. asintót. (bilateral) | ,016                  |

**Python vs C++**  
**U = 9439.000 · p = .016**

|                       | Lenguaje | N   | Rango promedio | Suma de rangos |
|-----------------------|----------|-----|----------------|----------------|
| Tiempo_Desarrollo_Min | Java     | 150 | 181,04         | 27155,50       |
|                       | C++      | 150 | 119,96         | 17994,50       |
|                       | Total    | 300 |                |                |

Estadísticos de contraste<sup>a</sup>

|                           | Tiempo_Desarrollo_Min |
|---------------------------|-----------------------|
| U de Mann-Whitney         | 6669,500              |
| W de Wilcoxon             | 17994,500             |
| Z                         | -6,097                |
| Sig. asintót. (bilateral) | ,000                  |

**Java vs C++**  
**U = 6669.500 · p < .001**

**Bonferroni:  $\alpha$  ajustado = .0167**

# Friedman compara los IDEs en los mismos programadores

|               | Rango promedio |
|---------------|----------------|
| Bugs_VSCode   | 1,87           |
| Bugs_IntelliJ | 1,54           |
| Bugs_Eclipse  | 2,59           |

Estadísticos de contraste<sup>a</sup>

|               |        |
|---------------|--------|
| N             | 150    |
| Chi-cuadrado  | 95,142 |
| gl            | 2      |
| Sig. asintót. | ,000   |



Se rechaza H<sub>0</sub>: la cantidad de bugs detectados cambia según el IDE utilizado.



## Wilcoxon muestra que los tres IDEs difieren

**IntelliJ vs VS Code**

**$Z = -3.239$   
 $p = .001$**

Diferencia significativa

**Eclipse vs VS Code**

**$Z = -6.624$   
 $p < .001$**

Diferencia significativa

**Eclipse vs IntelliJ**

**$Z = -8.606$   
 $p < .001$**

Diferencia significativa

**Orden final: IntelliJ < VS Code < Eclipse en cantidad de bugs**

## Mi data confirma cuándo usar cada prueba

Kruskal-Wallis se usó porque los lenguajes forman grupos independientes y la normalidad no se cumplió.

Friedman se usó porque los mismos programadores fueron evaluados en tres IDEs.

**En ambos análisis el valor p fue menor que .05, por lo que se rechazó  $H_0$  y se realizaron comparaciones post hoc.**

**Conclusión: hay diferencias significativas y se identifican con post hoc**

# Conclusiones y recomendaciones

## Conclusiones

- Kruskal-Wallis y Friedman permiten comparar métodos sin exigir normalidad.
- La diferencia clave está en el tipo de grupos: independientes o relacionados.
- Ambas se basan en el análisis de rangos, no de valores originales.
- Un valor  $p$  significativo requiere una prueba post hoc para ubicar la diferencia.

## Recomendaciones

- Verificar siempre los supuestos antes de elegir entre prueba paramétrica o no.
- Usar Kruskal-Wallis con grupos distintos y Friedman con medidas repetidas.
- Complementar con pruebas post hoc para conclusiones más precisas.
- Aplicar estas pruebas en estudios educativos con muestras pequeñas o datos ordinales.